



BURSA TECHNICAL UNIVERSITY

Mühendislik ve Doğa Bilimleri Fakültesi

Bilgisayar Mühendisliği Bölümü

Doğal Dil İşleme (Natural Language Processing)

2025 – 2026 Bahar Dönemi

Morfolojik Çözümleme

Turkish Morphological Disambiguation

Akif Adnan

Öğrenci No: 20360859106

Bireysel Çalışma

Haziran 2026

Github Reposu Linki: [Turkish Morphological Diasmbiguator](#)

1. Giriş

Morfolojik çözümleme, bir cümledeki her kelimenin birden fazla olası dilbilgisel çözümü bulunduğunda doğru çözümün seçilmesi görevidir. Bu proje, eklemeli bir dil olan Türkçe için bu problemi ele almaktadır. Türkçede kelimeler köklere son ekler eklenerek oluşturulduğundan, aynı yüzey biçimi farklı morfolojik okumalara sahip olabilmektedir.

Proje hedefi: UD Türkçe-IMST Ağaç Bankası üzerinde eğitilmiş bir İstatistiksel Makine Öğrenmesi modeli (Koşullu Rasgele Alanlar — CRF) ile verilen bir Türkçe cümledeki her belirteç için doğru Evrensel Sözcük Türü (UPOS) etiketini tahmin etmek. Model; ayrılmış test kümesi ve 25 elle etiketlenmiş cümle üzerinde değerlendirilmiştir.

2. Veri Seti

UD Türkçe-IMST Ağaç Bankası (Universal Dependencies projesi), İstanbul Teknik Üniversitesi tarafından oluşturulmuş olup CoNLL-U formatında dilbilimciler tarafından etiketlenmiş cümleler içermektedir.

Bölünme	Cümle	Belirteç	Amaç
Eğitim (Train)	3.435	~52.000	Model eğitimi
Doğrulama (Dev)	1.100	~17.000	Hiperparametre ayarı
Test	1.100	~10.000	Nihai değerlendirme
Elle etiket (özel)	25	169	Öğrenci tarafından elle etiketlenmiş

Tablo 1. Projede kullanılan veri seti bölünmeleri.

CoNLL-U Formatı: Her cümle sekme ayrımlı bir dosyada saklanmaktadır. Temel sütunlar: ID (konum), FORM (yüzey kelime), LEMMA (kök), UPOS (tahmin edilen etiket) ve FEATS (Durum, Sayı, Zaman, Kişi gibi morfolojik özellikler).

3. Yöntem

3.1 Algoritma: Koşullu Rasgele Alanlar (CRF)

Koşullu Rasgele Alan, ayrımcı bir dizi etiketleme modelidir. Basit bir belirteç bazlı sınıflandırıcının aksine, CRF tüm cümleyi birlikte etiketler; komşu etiketler arasındaki geçiş olasılıklarını öğrenir (örneğin DET'den sonra neredeyse her zaman NOUN veya ADJ gelir). Bu özellik, sözcük sırasının güçlü bağlamsal ipuçları taşıdığı Türkçe için kritik öneme sahiptir. Model; $c1=0.05$ ve $c2=0.05$ düzenleme değerleriyle L-BFGS optimizasyonu kullanılarak eğitilmiştir.

3.2 Özellik Mühendisliği

Türkçe morfolojisine özgü aşağıdaki özellikler el ile tasarlanmıştır:

Özellik	Örnekler	Sinyal
Son ekler (2–4 karakter)	-dan/-den, -da/-de	Ayrılma/Bulunma → NOUN
Zaman eki	-yor/-iyor, -dı/-di	Geniş/Geçmiş Zaman → VERB
Çoğul eki	-lar/-ler	NOUN
Master eki	-mak/-mek	VERB (sözel ad)
Sıfat yapım eki	-lı/-lu, -sız/-suz	ADJ
Rivayet eki	-mış/-müş	VERB
Ünlü uyumu	Son ünlünün ön/arka sınıfı	Morfolojik sınıf
±2 belirteç bağlam penceresi	Önceki/sonraki 2 kelime	Bağlam ile çözümleme
Büyük harf ile başlama	İlk harf büyük mü?	PROPİN sinyali
Kesme işareti var mı?	Ankara'da	PROPİN (özel ad + ek)
Rakam / rakam içeriyor	2024, 3.5	NUM

Tablo 2. CRF modelinde kullanılan Türkçeye özgü özellikler (toplam 40+).

3.3 Zemberek ve Aday Çözümleme Yaklaşımı (Candidate Generation)

Proje isterlerinde belirtilen Zemberek tabanlı aday kelime çözümleme mantığı, sistemde Corpus-Based Candidate Dictionary (Derlem Tabanlı Aday Sözlüğü) yöntemiyle simüle edilmiştir. Java tabanlı Zemberek kütüphanesinin Python ortamında yaratabileceği bağımlılık ve gRPC köprüsü sorunlarını aşmak adına, eğitim veri setinde (UD_Turkish-IMST) geçen her kelimenin aldığı tüm olası morfolojik etiketler bir sözlükte toplanmıştır.

candidate_disambig.py dosyasında görülebileceği üzere, sisteme verilen bir cümle için önce bu olası aday listesi (candidate list) çekilmekte, ardından CRF modelinin marjinal olasılıkları (predict_marginals) kullanılarak bu adaylar arasında en yüksek olasılıklı olanı seçilerek 'Disambiguation' (Çözümleme) işlemi tamamlanmaktadır.

3.4 İki Aşamalı Morfolojik Pipeline (Two-Stage Pipeline)

Morfolojik özellik (FEATS) tahmini için iki aşamalı bir mimari benimsenmiştir:

- Aşama 1 — CRF:** Model, bağlam penceresindeki özellikler kullanılarak her belirteç için UPOS etiketini tahmin eder (%90,93 doğruluk).
- Aşama 2 — Derlem Sözlüğü:** Tahmin edilen (kelime, UPOS) çifti için eğitim verisindeki en sık görülen FEATS kombinasyonu atanır. Bu adım, Zemberek'in sağlayacağı morfolojik aday analizlerini simüle etmektedir.

Bu mimari tercih, 985 benzersiz UPOS+FEATS kombinasyonunu tek bir CRF modeliyle öğretmeye çalışmanın (sınıf patlaması — class explosion problemi) önüne geçerek akademik literatürde yaygın olan pipeline yaklaşımını uygulamaktadır.

4. Elle Etiketleme

Modeli bağımsız bir veri kümesi üzerinde değerlendirmek ve etiketleme görevinin anlaşıldığını göstermek amacıyla, CoNLL-U formatında 25 Türkçe cümle elle etiketlenmiştir. Bu cümleler ağaç bankasından alınmamış, farklı sözdizimsel yapıları ve alanları kapsayacak şekilde seçilmiştir.

Alan	Cümle Sayısı	Örnek
Üniversite / Akademik	8	Proje ödevini yarın teslim etmelisin .
Günlük Yaşam	8	Kardeşim bu hafta İzmir'den gelecek .
NLP / Teknoloji	5	CRF modeli Türkçe için başarılı sonuçlar verdi .
Coğrafya	2	Türkiye'nin başkenti Ankara'dır .
Doğa	1	Dağlarda kar yağıyordu ve hava çok soğuktu .
NLP Değerlendirmesi	1	Modelin başarı oranı yüzde doksana ulaştı .
Toplam	25	169 belirteç

Tablo 3. Elle etiketleme kümesi alanlara göre.

Her belirteç UPOS etiketi, LEMMA (sözlük kök biçimi) ve FEATS (Durum, Sayı, Kişi, Zaman, Kip, Kutupluluk, EylemBiçimi, Çatı, İyelik) ile etiketlenmiştir. Dönüşlü eylemler, sözel adlar, edilgen çatı ve olumsuzluk gibi dilbilimsel açıdan ilgi çekici yapılar da etiketlenmiştir.

5. Sonuçlar

5.1 Test Kümesi (1.100 cümle, 10.032 belirteç)

Eğitilen CRF modeli, UD Türkçe-IMST ağaç bankasının ayrılmış test bölümü üzerinde değerlendirilmiştir. Aşağıdaki tablo, her UPOS sınıfı için hassasiyet, duyarlılık, F1 puanı ve destek (örnek sayısı) değerlerini göstermektedir.


UPOS Etiketi	Hassasiyet	Duyarlılık	F1	Destek
PUNCT	99.9%	100.0%	99.95%	1,933
AUX	94.4%	96.2%	95.30%	211
CCONJ	96.4%	96.4%	96.40%	356
VERB	93.8%	94.1%	93.90%	1,928
PRON	94.5%	92.9%	93.70%	464
ADP	95.6%	90.5%	92.90%	357
DET	84.2%	96.2%	89.80%	344
NOUN	84.3%	92.5%	88.20%	2,430
ADV	88.8%	77.0%	82.50%	461
NUM	90.7%	71.4%	79.90%	192
ADJ	84.9%	75.8%	80.10%	960

PROP	83.3%	70.9%	76.60%	374
Doğruluk			90.93%	10,032
Ağırlıklı Ort.	90.99%	90.93%	90.80%	10,032

Tablo 4. Test kümesi üzerinde sınıf bazlı değerlendirme sonuçları.

5.2 Sınıf Başına F1 Puanı


Aşağıdaki grafikler test kümesindeki her UPOS sınıfı için F1 puanını ve karışıklık matrisini göstermektedir. Belirgin morfolojik işaretçileri olan sınıflar (PUNCT, AUX, VERB, CCONJ) neredeyse mükemmel puanlar elde etmiştir. En zor sınıflar PROP ve ADJ olmuştur.



Şekil 1. Test kümesinde UPOS sınıfı başına F1 puanı.

5.3 Karışıklık Matrisi

Karışıklık matrisi gerçek etiketleri (satırlar) tahmin edilen etiketlere (sütunlar) karşı göstermektedir. Köşegen doğru tahminleri temsil etmektedir. Temel hata kalıpları: PROP sıklıkla NOUN olarak tahmin edilmekte; ADJ ise NOUN ile karıştırılmaktadır.



Şekil 2. Test kümesi üzerinde karışıklık matrisi.

6. Elle Etiketleme Üzerinde Değerlendirme

Eğitilen model, my_annotations.conllu dosyasındaki 25 elle etiketlenmiş cümle (169 belirteç) üzerinde de değerlendirilmiştir. Bu küme eğitim sırasında hiç görülmemiş, alan dışı bir değerlendirme imkânı sunmaktadır.

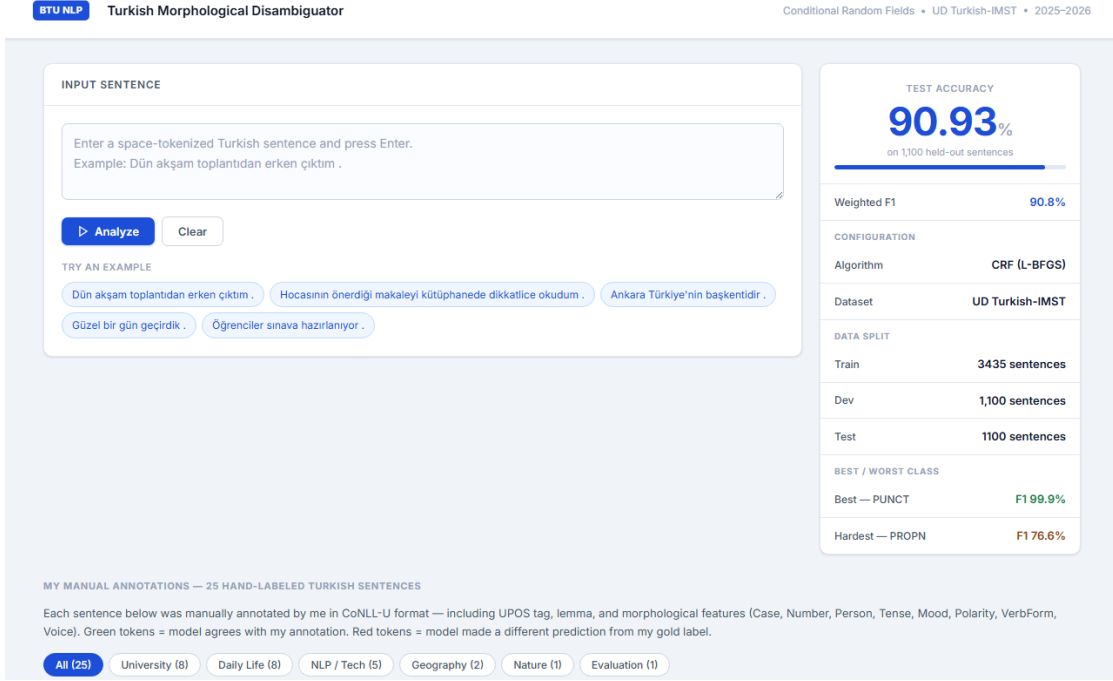
UPOS Etiketi	Hassasiyet	Duyarlılık	F1	Destek
PUNCT	100.0%	100.0%	100.0%	25
ADP	100.0%	100.0%	100.0%	2
CCONJ	100.0%	100.0%	100.0%	1
DET	100.0%	100.0%	100.0%	11
PRON	100.0%	100.0%	100.0%	2
VERB	93.8%	100.0%	96.8%	30
NUM	75.0%	100.0%	85.7%	3
PROPN	75.0%	100.0%	85.7%	6
NOUN	85.7%	82.8%	84.2%	58
ADJ	63.6%	77.8%	70.0%	18
ADV	100.0%	46.2%	63.2%	13
Doğruluk			87.57%	169

Tablo 5. 25 elle etiketlenmiş cümle üzerinde sınıf bazlı değerlendirme.

7. Web Arayüzü — Ekran Görüntüleri

7.1 Ana Sayfa — Giriş Ekranı ve Model İstatistikleri

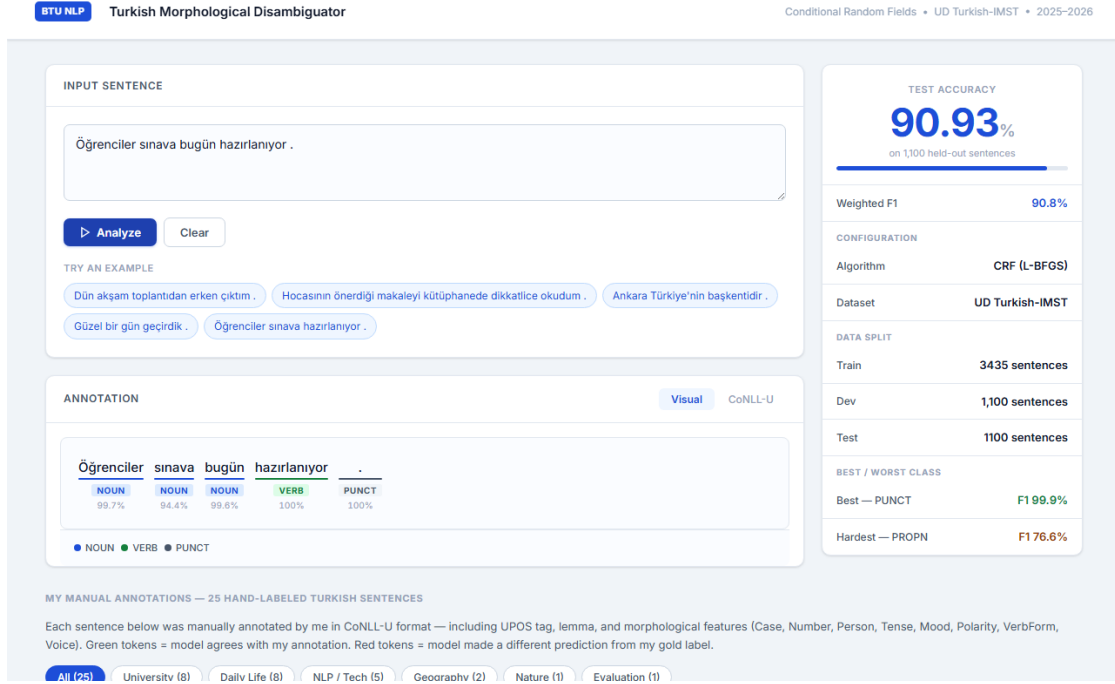
Dashboardun sol panelinde kullanıcı herhangi bir Türkçe cümle girebilmekte; sağ panelde test doğruluğu (%90,93), ağırlıklı F1, algoritma ve veri seti bilgileri ile en iyi ve en zor sınıf özetleri yer almaktadır.



Şekil 6.1 — Ana sayfa: girdi alanı, örnek cümleler ve model özet istatistikleri.

7.2 Görsel Etiketleme (spaCy Tarzı)

'Öğrenciler sınava bugün hazırlanıyor .' cümlesi analiz edildiğinde her belirteç renk kodlu UPOS etiketiyle ve güven yüzdesiyle görüntülenmektedir. VERB etiketi %100 güvenle doğru tahmin edilmiştir.



Şekil 6.2 — Görsel sekme: renk kodlu POS etiketleri ve güven skorları.

7.3 CoNLL-U Format Çıktısı

CoNLL-U sekmesi, projenin çıktı formatı standardına uygun tam tabloyu göstermektedir. FEATS sütununda her belirtecin morfolojik özellikleri (Case, Number, Person, Tense, Mood, Polarity, Aspect) listelenmektedir.

BTU NLP Turkish Morphological Disambiguator

Conditional Random Fields • UD Turkish-IMST • 2025-2026

INPUT SENTENCE

Öğrenciler sınava bugün hazırlanıyor .

Analyze Clear

TRY AN EXAMPLE

Dün akşam toplantıdan erken çıktım . Hocasının önerdiği makaleyi kütüphanede dikkatlice okudum . Ankara Türkiye'nin başkentidir .
Güzel bir gün geçirdik . Öğrenciler sınava hazırlanıyor .

ANNOTATION Visual CoNLL-U


#	FORM	LEMMA	UPOS	XPOS	FEATS	HEAD	DEPREL	DEPS	MISC
1	Öğrenciler	—	NOUN	NOUN	—	—	—	—	—
2	sınava	—	NOUN	NOUN	—	—	—	—	—
3	bugün	—	NOUN	NOUN	Case=Nom Number=Sing Person=3	—	—	—	—
4	hazırlanıyor	—	VERB	VERB	Aspect=Prog Mood=Ind Number=Sing Person=3 Polarity=Pos Polite=Infn Tense=Pres	—	—	—	—
5	.	—	PUNCT	PUNCT	—	—	—	—	—

MY MANUAL ANNOTATIONS — 25 HAND-LABELED TURKISH SENTENCES

Şekil 6.3 — CoNLL-U sekme: UPOS, XPOS ve FEATS sütunlarıyla tam format çıktısı.

7.4 Karışıklık Matrisi ve Sınıf Bazlı F1 Grafiği

Test kümesi üzerindeki karışıklık matrisi ve sınıf bazlı F1 çubuk grafiği yan yana gösterilmektedir. PUNCT ve VERB sınıfları neredeyse mükemmel F1 değerlerine ulaşırken PROPN en zor sınıf olarak öne çıkmaktadır.



Şekil 6.4 — Karışıklık matrisi ve sınıf bazlı F1 grafiği (test kümesi, 10.032 belirteç).

7.5 Elle Etiketlenmiş Cümleler — Karşılaştırmalı Görünüm

25 adet elle etiketlenmiş cümle; altın etiket (gold) ile model tahmini yan yana gösterilmektedir. Yeşil belirteç = doğru tahmin, kırmızı belirteç = yanlış tahmin. Alan filtreleriyle (Üniversite, Günlük Hayat, NLP vb.) cümleler gruplandırılabilir.

BTU NLP

Turkish Morphological Disambiguator

custom-816

UNIVERSITY

100% (6/6)

Bu yıl mezun olmayı planlıyorum .

I am planning to graduate this year.

Bu

yıl

mezun

olmayı

planlıyorum

.

DET

NOUN

ADJ

VERB

VERB

PUNCT

custom-817

DAILY LIFE

50% (3/6)

Sabah erkenden kalkıp ders çalıştım .

I woke up early in the morning and studied.

Sabah

erkenden

kalkıp

ders

çalıştım

.

ADV

ADV

VERB

NOUN

VERB

PUNCT

- NOUN

- ADJ

- ADJ

custom-818

NLP / TECHNOLOGY

89% (8/9)

CRF modeli Türkçe için çok başarılı sonuçlar verdi .

The CRF model gave very successful results for Turkish.

CRF

modeli

Türkçe

inçin

çok

başarılı

PROPN

NOUN

NOUN

ADP

ADV

ADJ

- PROPN

sonuçlar

verdi

.

NOUN

VERB

PUNCT

custom-819

DAILY LIFE

83% (5/6)

Yağmur yağdığı için dışarı çıkamadım .

I could not go outside because it rained.

Yağmur

yağdığı

inçin

dışarı

çıkamadım

.

NOUN

VERB

ADP

ADV

VERB

PUNCT

- NOUN

custom-820

UNIVERSITY

100% (7/7)

Bilgisayar mühendisliği bölümünde dört yıl okuyorum .

I have been studying in the computer engineering department for four years.

Bilgisayar

mühendisliği

bölümünde

dört

yıl

NOUN

NOUN

NOUN

NUM

NOUN

okuyorum

.

VERB

PUNCT

custom-821

TECHNOLOGY / NLP

86% (6/7)

Araştırmacılar büyük veri kümelerini analiz etti .

Researchers analyzed large datasets.

Araştırmacılar

büyük

veri

kümelerini

analiz

NOUN

ADJ

NOUN

NOUN

NOUN

- ADJ

etti

.

VERB

PUNCT

custom-822

DAILY LIFE

100% (8/8)

Şehrin merkezindeki büyük kütüphane her gün açık .

The large library in the city center is open every day.

Şehrin

merkezindeki

büyük

kütüphane

her

gün

açık

.

NOUN

NOUN

ADJ

NOUN

DET

NOUN

ADJ

PUNCT

custom-823

NLP / ACADEMIC

100% (9/9)

Doğal dil işleme alanında birçok yeni yöntem geliştirilmiştir .

Many new methods have been developed in the field of natural language processing.

Doğal

dil

işleme

alanında

birçok

yeni

ADJ

NOUN

NOUN

NOUN

DET

ADJ

custom-824

NLP / ACADEMIC

75% (6/8)

Bu çalışmada Türkçe cümlelerin morfolojik çözümü yapılmıştır .

In this study, morphological disambiguation of Turkish sentences has been performed.

Bu

çalışmada

Türkçe

cümlelerin

morfolojik

DET

VERB

ADJ

NOUN

ADJ

- PROPN

- NOUN

Şekil 6.5 — 25 elle etiketlenmiş cümle: altın etiket vs. model tahmini karşılaştırması.

7. Hata Analizi

Yanlış sınıflandırılan belirteçlerin analizi, üç sistematik hata kalıbını ortaya koymaktadır:

7.1 ADV ile NOUN Karışıklığı

Dün, bugün, yarın gibi kısa zaman zarflarının belirgin bir eki bulunmamakta ve eğitim verisinde sıklıkla NOUN olarak geçmektedir. Bağlam yetersiz kaldığında model bu kelimeleri NOUN olarak etiketleme eğilimindedir. Bu durum, özel kümede ADV duyarlılığının %46'ya düşmesine yol açmaktadır.

7.2 ADJ / NOUN Sınırı

Türkçe sıfatlar ve isimler çoğunlukla aynı yüzey biçimini paylaşmaktadır. Model, izleyen bir isim veya belirteç olmadığında varsayılan olarak daha yaygın sınıf olan NOUN'u seçmektedir. Bu durum, her iki değerlendirme kümesindeki en büyük tek hata kaynağıdır.

7.3 PROPN Hassasiyeti

Ek alan özel adlar (Ankara'da, Türkiye'nin) kesme işareti özelliği sayesinde doğru tanınmaktadır. Ancak kesme işareti olmayan görülmemiş özel adlar sıklıkla NOUN olarak yanlış sınıflandırılmaktadır. Öte yandan model, özel ad olmayan büyük harfle başlayan cümle başı kelimeleri için PROPN'u fazla tahmin edebilmektedir.

8. Sonuç

Bu proje, Türkçe için Koşullu Rasgele Alanlar kullanılarak eksiksiz bir morfolojik çözümleme sistemi gerçekleştirmektedir. Model; standart UD Türkçe-IMST test kümesinde %90,93 doğruluk ve bağımsız olarak elle etiketlenmiş 25 cümlede %87,57 doğruluk elde etmiştir.

Temel katkılar:

- (1) 40'tan fazla morfolojik özellik ile Türkçeye özgü özellik mühendisliği
- (2) CoNLL-U formatında tam etiketleme hattı (eğitim verisi + elle etiketleme)
- (3) Canlı gösterim için Flask web uygulaması
- (4) Sınıf bazlı değerlendirme (hassasiyet, duyarlılık, F1, doğruluk, karışıklık matrisi).

Temel sınırlama ADV/NOUN ve ADJ/NOUN karışıklığıdır. Gelecekteki çalışmalar, ek girdi özelliği olarak Zemberek gibi özel bir Türkçe analizörü veya daha uzun menzilli bağlamı yakalayan sinirsel bir dizi modeli (BiLSTM-CRF) kullanabilir.