



**BURSA TECHNICAL
UNIVERSITY**

T.C. Bursa Teknik Üniversitesi

Mühendislik ve Doğa Bilimleri Fakültesi

Bilgisayar Mühendisliği Bölümü

Doğal Dil İşleme (Natural Language Processing)

2025 – 2026 Bahar Dönemi

Morfolojik Çözümleme

Turkish Morphological Disambiguation

Akif Adnan

Öğrenci No: 20360859106

Bireysel Çalışma

Haziran 2026

1. Giriş

Morfolojik çözümleme, bir cümledeki her kelimenin birden fazla olası dilbilgisel çözümü bulunduğu doğru çözümün seçilmesi görevidir. Bu proje, eklemeli bir dil olan Türkçe için bu problemi ele almaktadır. Türkçede kelimeler köklere son ekler eklenerek oluşturulduğundan, aynı yüzey biçimi farklı morfolojik okumalara sahip olabilmektedir.

Proje hedefi: UD Türkçe-IMST Ağaç Bankası üzerinde eğitilmiş bir İstatistiksel Makine Öğrenmesi modeli (Koşullu Rasgele Alanlar — CRF) ile verilen bir Türkçe cümledeki her belirteç için doğru Evrensel Sözcük Türü (UPOS) etiketini tahmin etmek. Model; ayrılmış test kümesi ve 25 elle etiketlenmiş cümle üzerinde değerlendirilmiştir.

2. Veri Seti

UD Türkçe-IMST Ağaç Bankası (Universal Dependencies projesi), İstanbul Teknik Üniversitesi tarafından oluşturulmuş olup CoNLL-U formatında dilbilimciler tarafından etiketlenmiş cümleler içermektedir.

Bölünme	Cümle	Belirteç	Amaç
Eğitim (Train)	3.435	~52.000	Model eğitimi
Doğrulama (Dev)	1.100	~17.000	Hiperparametre ayarı
Test	1.100	~10.000	Nihai değerlendirme
Elle etiket (özel)	25	169	Öğrenci tarafından elle etiketlenmiş

Tablo 1. Projede kullanılan veri seti bölünmeleri.

CoNLL-U Formatı: Her cümle sekme ayrımlı bir dosyada saklanmaktadır. Temel sütunlar: ID (konum), FORM (yüzey kelime), LEMMA (kök), UPOS (tahmin edilen etiket) ve FEATS (Durum, Sayı, Zaman, Kişi gibi morfolojik özellikler).

3. Yöntem

3.1 Algoritma: Koşullu Rasgele Alanlar (CRF)

Koşullu Rasgele Alan, ayrımcı bir dizi etiketleme modelidir. Basit bir belirteç bazlı sınıflandırıcının aksine, CRF tüm cümleyi birlikte etiketler; komşu etiketler arasındaki geçiş olasılıklarını öğrenir (örneğin DET'den sonra neredeyse her zaman NOUN veya ADJ gelir). Bu özellik, sözcük sırasının güçlü bağlamsal ipuçları taşıdığı Türkçe için kritik öneme sahiptir. Model; $c1=0.05$ ve $c2=0.05$ düzenleme değerleriyle L-BFGS optimizasyonu kullanılarak eğitilmiştir.

3.2 Özellik Mühendisliği

Türkçe morfolojisine özgü aşağıdaki özellikler el ile tasarlanmıştır:

Özellik	Örnekler	Sinyal
Son ekler (2–4 karakter)	-dan/-den, -da/-de	Ayrılma/Bulunma → NOUN
Zaman eki	-yor/-iyor, -dı/-di	Geniş/Geçmiş Zaman → VERB
Çoğul eki	-lar/-ler	NOUN
Master eki	-mak/-mek	VERB (sözel ad)
Sıfat yapım eki	-lı/-lu, -sız/-suz	ADJ
Rivayet eki	-mış/-müş	VERB
Ünlü uyumu	Son ünlünün ön/arka sınıfı	Morfolojik sınıf
± 2 belirteç bağlam penceresi	Önceki/sonraki 2 kelime	Bağlam ile çözümleme
Büyük harf ile başlama	İlk harf büyük mü?	PROPN sinyali
Kesme işareti var mı?	Ankara'da	PROPN (özel ad + ek)
Rakam / rakam içeriyor	2024, 3.5	NUM

Tablo 2. CRF modelinde kullanılan Türkçeye özgü özellikler (toplam 40+).

3.3 Zemberek ve Aday Çözümleme Yaklaşımı (Candidate Generation)

Proje isterlerinde belirtilen Zemberek tabanlı aday kelime çözümleme mantığı, sistemde Corpus-Based Candidate Dictionary (Derlem Tabanlı Aday Sözlüğü) yöntemiyle simüle edilmiştir. Java tabanlı Zemberek kütüphanesinin Python ortamında yaratabileceği bağımlılık ve gRPC köprüsü sorunlarını aşmak adına, eğitim veri setinde (UD_Turkish-IMST) geçen her kelimenin aldığı tüm olası morfolojik etiketler bir sözlükte toplanmıştır.

candidate_disambig.py dosyasında görülebileceği üzere, sisteme verilen bir cümlenin her kelimesi için önce bu olası aday listesi (candidate list) çekilmekte, ardından CRF modelinin marjinal olasılıkları (predict_marginals) kullanılarak bu adaylar arasında en yüksek olasılıklı olanı seçilerek 'Disambiguation' (Çözümleme) işlemi tamamlanmaktadır.

3.4 İki Aşamalı Morfolojik Pipeline (Two-Stage Pipeline)

Morfolojik özellik (FEATS) tahmini için iki aşamalı bir mimari benimsenmiştir:

- **Aşama 1 — CRF:** Model, bağlam penceresindeki özellikler kullanılarak her belirteç için UPOS etiketini tahmin eder (%90,93 doğruluk).
- **Aşama 2 — Derlem Sözlüğü:** Tahmin edilen (kelime, UPOS) çifti için eğitim verisindeki en sık görülen FEATS kombinasyonu atanır. Bu adım, Zemberek'in sağlayacağı morfolojik aday analizlerini simüle etmektedir.

Bu mimari tercih, 985 benzersiz UPOS+FEATS kombinasyonunu tek bir CRF modeliyle öğretmeye çalışmanın (sınıf patlaması — class explosion problemi) önüne geçerek akademik literatürde yaygın olan pipeline yaklaşımını uygulamaktadır.

4. Elle Etiketleme

Modeli bağımsız bir veri kümesi üzerinde değerlendirmek ve etiketleme görevinin anlaşıldığını göstermek amacıyla, CoNLL-U formatında 25 Türkçe cümle elle etiketlenmiştir. Bu cümleler ağaç bankasından alınmamış, farklı sözdizimsel yapıları ve alanları kapsayacak şekilde seçilmiştir.

Alan	Cümle Sayısı	Örnek
Üniversite / Akademik	8	Proje ödevini yarın teslim etmelisin .
Günlük Yaşam	8	Kardeşim bu hafta İzmir'den gelecek .
NLP / Teknoloji	5	CRF modeli Türkçe için başarılı sonuçlar verdi .
Coğrafya	2	Türkiye'nin başkenti Ankara'dır .
Doğa	1	Dağlarda kar yağıyordu ve hava çok soğuktu .
NLP Değerlendirmesi	1	Modelin başarı oranı yüzde doksana ulaştı .
Toplam	25	169 belirteç

Tablo 3. Elle etiketleme kümesi alanlara göre.

Her belirteç UPOS etiketi, LEMMA (sözlük kök biçimi) ve FEATS (Durum, Sayı, Kişi, Zaman, Kip, Kutupluluk, EylemBiçimi, Çatı, İyelik) ile etiketlenmiştir. Dönüştürme eylemler, sözel adlar, edilgen çatı ve olumsuzluk gibi dilbilimsel açıdan ilgi çekici yapılar da etiketlenmiştir.

5. Sonular

5.1 Test Kmesi (1.100 cmle, 10.032 belirte)


Eđitilen CRF modeli, UD Trke-IMST ađa bankasının ayrılmıř test blm zerinde deđerlendirilmiřtir. Ařađıdaki tablo, her UPOS sınıfı iin hassasiyet, duyarlılık, F1 puanı ve destek (rnek sayısı) deđerlerini gstermektedir.

UPOS Etiketi	Hassasiyet	Duyarlılık	F1	Destek
PUNCT	99.9%	100.0%	99.95%	1,933
AUX	94.4%	96.2%	95.30%	211
CCONJ	96.4%	96.4%	96.40%	356
VERB	93.8%	94.1%	93.90%	1,928
PRON	94.5%	92.9%	93.70%	464
ADP	95.6%	90.5%	92.90%	357
DET	84.2%	96.2%	89.80%	344
NOUN	84.3%	92.5%	88.20%	2,430
ADV	88.8%	77.0%	82.50%	461
NUM	90.7%	71.4%	79.90%	192
ADJ	84.9%	75.8%	80.10%	960
PROPN	83.3%	70.9%	76.60%	374
Dođruluk			90.93%	10,032
Ađırlıklı Ort.	90.99%	90.93%	90.80%	10,032

Tablo 4. Test kmesi zerinde sınıf bazlı deđerlendirme sonuları.

5.2 Sınıf Bařına F1 Puanı


Ařađıdaki grafikler test kmesindeki her UPOS sınıfı iin F1 puanını ve karıřıklık matrisini gstermektedir. Belirgin morfolojik iřaretileri olan sınıflar (PUNCT, AUX, VERB, CCONJ) neredeyse mkemmел puanlar elde etmiřtir. En zor sınıflar PROPN ve ADJ olmuřtur.



řekil 1. Test kmesinde UPOS sınıfı bařına F1 puanı.

5.3 Karışıklık Matrisi

Karışıklık matrisi gerçek etiketleri (satırlar) tahmin edilen etiketlere (sütunlar) karşı göstermektedir. Köşegen doğru tahminleri temsil etmektedir. Temel hata kalıpları: PROPN sıklıkla NOUN olarak tahmin edilmekte; ADJ ise NOUN ile karıştırılmaktadır.



Şekil 2. Test kümesi üzerinde karışıklık matrisi.

6. Elle Etiketleme Üzerinde Değerlendirme

Eğitilen model, my_annotations.conllu dosyasındaki 25 elle etiketlenmiş cümle (169 belirteç) üzerinde de değerlendirilmiştir. Bu küme eğitim sırasında hiç görülmemiş, alan dışı bir değerlendirme imkânı sunmaktadır.

UPOS Etiketi	Hassasiyet	Duyarlılık	F1	Destek
PUNCT	100.0%	100.0%	100.0%	25
ADP	100.0%	100.0%	100.0%	2
CCONJ	100.0%	100.0%	100.0%	1
DET	100.0%	100.0%	100.0%	11
PRON	100.0%	100.0%	100.0%	2
VERB	93.8%	100.0%	96.8%	30
NUM	75.0%	100.0%	85.7%	3
PROPN	75.0%	100.0%	85.7%	6
NOUN	85.7%	82.8%	84.2%	58
ADJ	63.6%	77.8%	70.0%	18
ADV	100.0%	46.2%	63.2%	13
Doğruluk			87.57%	169

Tablo 5. 25 elle etiketlenmiş cümle üzerinde sınıf bazlı değerlendirme.

Model özel kümede %87,57 doğruluk elde etmiş; bu sonuç modelin eğitim verisinin ötesine genelleşebildiğini doğrulamaktadır. Test kümesinden (%90,93) özel kümeye (%87,57) düşüş beklenen bir durumdur — özel cümleler daha karmaşık yapılar (dönüslü eylemler, sözel adlar, edilgen çatı) ve alışılmışın dışında kelimeler içermektedir.

7. Hata Analizi

Yanlış sınıflandırılan belirteçlerin analizi, üç sistematik hata kalıbını ortaya koymaktadır:

7.1 ADV ile NOUN Karışıklığı

Dün, bugün, yarın gibi kısa zaman zarflarının belirgin bir eki bulunmamakta ve eğitim verisinde sıklıkla NOUN olarak geçmektedir. Bağlam yetersiz kaldığında model bu kelimeleri NOUN olarak etiketleme eğilimindedir. Bu durum, özel kümede ADV duyarlılığının %46'ya düşmesine yol açmaktadır.

7.2 ADJ / NOUN Sınırı

Türkçe sıfatlar ve isimler çoğunlukla aynı yüzey biçimini paylaşmaktadır. Model, izleyen bir isim veya belirteç olmadığında varsayılan olarak daha yaygın sınıf olan NOUN'u seçmektedir. Bu durum, her iki değerlendirme kümesindeki en büyük tek hata kaynağıdır.

7.3 PROPN Hassasiyeti

Ek alan özel adlar (Ankara'da, Türkiye'nin) kesme işareti özelliği sayesinde doğru tanınmaktadır. Ancak kesme işareti olmayan görülmemiş özel adlar sıklıkla NOUN olarak yanlış sınıflandırılmaktadır. Öte yandan model, özel ad olmayan büyük harfle başlayan cümle başı kelimeleri için PROPN'u fazla tahmin edebilmektedir.

8. Sonuç

Bu proje, Türkçe için Koşullu Rasgele Alanlar kullanılarak eksiksiz bir morfolojik çözümleme sistemi gerçekleştirmektedir. Model; standart UD Türkçe-IMST test kümesinde %90,93 doğruluk ve bağımsız olarak elle etiketlenmiş 25 cümlede %87,57 doğruluk elde etmiştir.

Temel katkılar:

- (1) 40'tan fazla morfolojik özellik ile Türkçeye özgü özellik mühendisliği
- (2) CoNLL-U formatında tam etiketleme hattı (eğitim verisi + elle etiketleme)
- (3) Canlı gösterim için Flask web uygulaması
- (4) Sınıf bazlı değerlendirme (hassasiyet, duyarlılık, F1, doğruluk, karışıklık matrisi).

Temel sınırlama ADV/NOUN ve ADJ/NOUN karışıklığıdır. Gelecekteki çalışmalar, ek girdi özelliği olarak Zemberek gibi özel bir Türkçe analizörü veya daha uzun menzilli bağlamı yakalayan sinirsel bir dizi modeli (BiLSTM-CRF) kullanabilir.